



Bloc Math3

« Optimisation et traitement du signal avancé »

École associée
INSTITUT
Mines-Télécom

OPTIMISATION CONTINUE


télécom
saint-étienne
école d'ingénieurs
nouvelles technologies



S.ROBERT

2014-2015

FI2

6 CM 9 TD

Information pratique

Contenu

- I Définitions et formulation
- II Résolution d'équations
- III Méthodes d'Optimisation sans contrainte

Evaluation du module

Evaluation écrite

40%

Durée: 1h00

Documents autorisés:

Polycopiés de Cours, Notes de cours

Calculatrice fournie

Evaluation par projet

60%

Travail collectif par binôme

Durée: 9 h



Chapitre I

Définitions et formulation

I

II

III

Formulation d'un problème d'optimisation

Fonction Objectif

Les contraintes ...

3



I) Définitions et formulation

A) Formulation d'un problème d'optimisation

→ **Optimisation** ↔ Identifier une configuration optimale ou un **optimal** d'un système



Trouver le minimum d'une fonction $f(x)$

I

II

III

Optimiser un processus physique



Modélisation Mathématique du processus

→ Identifier les **variables de décision** sur lesquelles on peut agir

$$\vec{x} = \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$$

→ Définir la mesure de l'état du système par une **fonction objectif**

$$f(\vec{x}) \text{ ou } f(\mathbf{x}) \in \mathbb{R}$$

→ Définir par des **contraintes** les valeurs autorisées que peuvent prendre les variables x

$$\mathbf{x} \in X \subset \mathbb{R}^n$$



Le choix des variables x n'est pas forcément immédiat. De plus, il conditionne le résultat de l'optimisation

4



I) Définitions et formulation

A) Formulation d'un problème d'optimisation



Exemples de problèmes d'optimisation

Exemple 1

Entreprise de Télécommunication



Optimisation du lieu d'implantation d'une nouvelle antenne

2 antennes existantes : (-5;10) et (5;0)



Connexion de 4 nouveaux clients

(5;10) 200 heures



(0;12) 200 heures



(10;5) 150 heures



(12;0) 300 heures




- Positon idéale: la plus proche possible du client
- Priorités données aux meilleurs clients
- Respect de la loi : distance minimal entre chaque antenne de 10 km

5



I) Définitions et formulation

A) Formulation d'un problème d'optimisation



Variables de décision

Définir une solution possible par l'emplacement de l'antenne

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Fonction objectif

Mesurer la pertinence d'une solution potentielle: antenne la plus proche possible du client + priorité pour le meilleur d'entre eux

Contraintes

Respecter une distance minimal avec antennes existantes

$$\sqrt{(x_1 + 5)^2 + (x_2 - 10)^2} \geq 10$$

$$\sqrt{(x_1 - 5)^2 + x_2^2} \geq 10$$

$$f(x_1, x_2) = 200\sqrt{(x_1 - 5)^2 + (x_2 - 10)^2} + 150\sqrt{(x_1 - 10)^2 + (x_2 - 5)^2} + 200\sqrt{x_1^2 + (x_2 - 12)^2} + 300\sqrt{(x_1 - 12)^2 + x_2^2}$$

Problème d'optimisation: $\min_{(x_1, x_2)} f(x_1, x_2)$ sous contraintes $\sqrt{(x_1 + 5)^2 + (x_2 - 10)^2} \geq 10$
 $\sqrt{(x_1 - 5)^2 + x_2^2} \geq 10$

6



I) Définitions et formulation

A) Formulation d'un problème d'optimisation



Exemple 2

Fabriqueur de jouet en bois
(soldats  + Train )



Optimisation du coût de
production par semaine

I
II
III

➤ Prix de vente :	27 €	21 €
➤ Matériel brut :	10 €	9 €
➤ Coût généraux :	14 €	10 €
➤ Menuiserie :	1 h	1 h
➤ Finissage :	2 h	1 h

- 2 menuisiers disponibles + 2 spécialistes du finissage (40h/semaine chacun)
- Patron travaille 20h/sem au finissage
- Quelque soit la production de trains , elle sera vendue
- Vente maximale de 40 soldats / semaine

Problème d'optimisation:



7



I) Définitions et formulation

A) Formulation d'un problème d'optimisation



Exemple 3

Enseignant Mr  part en retard
de son domicile pour dispenser son
cours d'optimisation




Optimisation du trajet domicile / travail
afin d'éviter ... le drame !!!

I
II
III

- Domicile situé à RAUBAIRVILLE rue de l'Electraumague près de l'autoroute
- Domicile à 20 km du point sur l'autoroute le plus proche de TELECOM Saint-Etienne
- Il peut sortir à tout moment pour emprunter une voie départementale qui le mènera tout droit à son travail
- Vitesse moyenne sur autoroute: 110 km/h
- Vitesse moyenne sur voie départementale : 70 km/h

Problème d'optimisation:



8



I) Définitions et formulation

B) Reformulation !!!

Algorithmes et/ou logiciels
d'optimisation impose une
formulation propre



Transformation de
la fonction objectif

→ Equivalence



2 problèmes d'optimisation P1 et P2 sont dits équivalents si l'on peut construire un **point admissible** de P2 à partir d'un point admissible de P1 (et réciproquement) avec la même valeur pour la fonction objectif

→ Transformations simples

→ Composition par une fonction $s : \mathbb{R} \rightarrow \mathbb{R}$
strictement croissante sur $\text{Im}(f) = \{z \mid \exists x \in X \text{ tq } z = f(x)\}$

$$\begin{aligned} \min_{x \in X \subseteq \mathbb{R}^n} s(f(x)) &= s\left(\min_{x \in X \subseteq \mathbb{R}^n} f(x)\right) \\ \arg \min_{x \in X \subseteq \mathbb{R}^n} f(x) &= \arg \min_{x \in X \subseteq \mathbb{R}^n} s(f(x)) \end{aligned}$$

Opérateur Min et argmin

Min identifie le minimum de la fonction
Argmin identifie la valeur des variables qui
correspondent au minimum de la fonction

9



I) Définitions et formulation

B) Reformulation !!!

En particulier ...

➤ $\forall c \in \mathbb{R} \quad \arg \min_{x \in X \subseteq \mathbb{R}^n} f(x) = \arg \min_{x \in X \subseteq \mathbb{R}^n} (f(x) + c)$

$$\min_{x \in X \subseteq \mathbb{R}^n} (f(x) + c) = c + \min_{x \in X \subseteq \mathbb{R}^n} (f(x))$$

➤ si $f(x) > 0 \quad \arg \min_{x \in X \subseteq \mathbb{R}^n} f(x) = \arg \min_{x \in X \subseteq \mathbb{R}^n} \log(f(x))$

$$\min_{x \in X \subseteq \mathbb{R}^n} \log(f(x)) = \log\left(\min_{x \in X \subseteq \mathbb{R}^n} f(x)\right)$$

➤ si $f(x) \geq 0 \quad \arg \min_{x \in X \subseteq \mathbb{R}^n} f(x) = \arg \min_{x \in X \subseteq \mathbb{R}^n} (f(x))^2$

$$\min_{x \in X \subseteq \mathbb{R}^n} (f(x))^2 = \left(\min_{x \in X \subseteq \mathbb{R}^n} f(x)\right)^2$$

Etc ...

➔ Minimum ↔ maximum

$$\begin{aligned} \max_{x \in X \subseteq \mathbb{R}^n} f(x) &= - \min_{x \in X \subseteq \mathbb{R}^n} (-f(x)) \\ \arg \max_{x \in X \subseteq \mathbb{R}^n} f(x) &= \arg \min_{x \in X \subseteq \mathbb{R}^n} (-f(x)) \end{aligned}$$



*Dans la suite, on se ramènera
souvent à une minimisation
plutôt qu'une maximisation*

10



I) Définitions et formulation

B) Reformulation !!!

→ Transformation des contraintes



Généralement utilisé lorsque les contraintes sont linéaires

➤ Inégalité inférieure \Leftrightarrow Inégalité supérieure

$$g(x) \leq 0 \Leftrightarrow -g(x) \geq 0$$

➤ Egalité \Leftrightarrow Inégalités

$$g(x) = 0 \Leftrightarrow \begin{cases} g(x) \leq 0 \\ g(x) \geq 0 \end{cases}$$

➤ Changement de variable $x = \tilde{x} + a$ avec $a \in \mathbb{R}$

$$x \geq a \Leftrightarrow \tilde{x} \geq 0$$



Considérons le problème d'optimisation suivant:

$$\max_{x,y} (-x^2 + \sin y)$$

sous contraintes

$$\begin{cases} 6x^2 - y^2 \geq 1 \\ x^2 + y^2 = 10 \\ x \geq 2 \\ y \in \mathbb{R} \end{cases}$$

Reformuler le problème de manière à obtenir un problème de minimisation dont toutes les variables de décision sont positives ou nulles et les contraintes définies par des inégalités inférieures



11



I) Définitions et formulation

B) Reformulation !!!

➤ Inégalité \Leftrightarrow Egalité (+ positivité) → Introduction d'une variable de décision: **variable d'écart** z (ou y)

$$g(x) \leq 0 \Leftrightarrow g(x) + z^2 = 0 \quad \text{ou} \quad \begin{cases} g(x) + y = 0 \\ y \geq 0 \end{cases}$$



La fonction objectif n'est pas affectée par l'introduction des variables de d'écart



Considérons le problème d'optimisation suivant:

$$\min_{x_1, x_2} (x_1^2 - x_2^2)$$

sous contraintes

$$\begin{cases} \sin x_1 \leq \frac{\pi}{2} \\ \ln(e^{x_1} + e^{x_2}) \geq \sqrt{e} \end{cases}$$

Reformuler le problème de manière à obtenir des contraintes définies par des égalités et/ou des contraintes de positivité par l'introduction de variables d'écart



12



I) Définitions et formulation

C) Hypothèses restrictives

Domaine de l'optimisation très vaste !!! \longleftrightarrow Restrictions du cours

→ Hypothèse de continuité



Exemple 2 ne vérifie pas l'hypothèse

sinon

Optimisation combinatoire ou programmation en nombres entiers

(Cf cours Option math TSE2)

Fonction objectif et fonctions définissant les contraintes



Fonctions continues des variables de décision

→ Hypothèse de différentiabilité (implique l'hypothèse de continuité)

sinon

Optimisation non différentiable

Fonction objectif et fonctions définissant les contraintes



Fonctions différentiables des variables de décision

→ Hypothèse de déterminisme

Ignorer les erreurs de modèles (bruit de mesure, ...)

sinon

**Optimisation stochastique
Optimisation robuste**

(Cf cours Option math TSE2)

13



I) Définitions et formulation

D) Définitions complètes

→ Problème d'optimisation

à n variables de décision, m contraintes d'égalités et p contraintes d'inégalités

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{sous contraintes} \quad \begin{cases} h(\mathbf{x}) = 0 \\ g(\mathbf{x}) \leq 0 \end{cases} \quad \text{et} \quad \mathbf{x} \in X$$

➤ $f: \mathbb{R}^n \rightarrow \mathbb{R}$

➤ $h: \mathbb{R}^n \rightarrow \mathbb{R}^m$

➤ $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$

➤ $X \subseteq \mathbb{R}^n$ ensemble convexe des solutions (admissible ou non)

Ensemble convexe

$X \subseteq \mathbb{R}^n$ est convexe si $\forall \mathbf{x}, \mathbf{y} \in X$
on a $\lambda \mathbf{x} + (1-\lambda) \mathbf{y} \in X$ avec $0 \leq \lambda \leq 1$

L'ensemble Y des **points admissibles** est défini par :

$$Y = \{ \mathbf{x} \in \mathbb{R}^n \mid h(\mathbf{x}) = 0, g(\mathbf{x}) \leq 0 \text{ et } \mathbf{x} \in X \}$$

14



I) Définitions et formulation

D) Définitions complètes

Types de solutions

Minimum local

Aucun de ses voisins immédiats admissibles n'est meilleur



$x^* \in Y$ est minimum local s'il existe $\varepsilon > 0$ tq

$$f(x^*) \leq f(x) \quad \forall x \in Y \text{ tq } \|x - x^*\| < \varepsilon$$

Minimum global

Aucun des points admissibles n'est meilleur



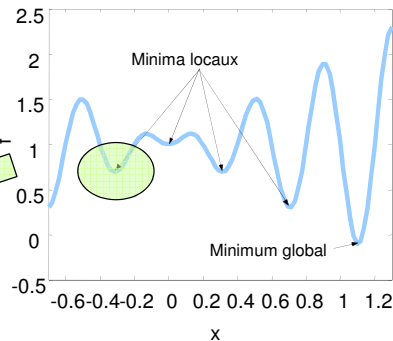

$x^* \in Y$ est minimum global si

$$f(x^*) \leq f(x) \quad \forall x \in Y$$



On parle de minimum local et/ou global **strict** lorsque $f(x^*) < f(x) \quad \forall x \in Y \text{ avec } x \neq x^*$

Exemple d'intervalle pour lequel $f(x^*) \leq f(x)$



Certaines fonctions peuvent comporter des minima locaux sans qu'un minimum global n'existe



I) Définitions et formulation

D) Définitions complètes

Infimum

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ non bornée

Possibilité de problème sans optimum



$$\min_{x \in \mathbb{R}} f(x) = \min_{x \in \mathbb{R}} x$$

f bornée inférieurement sur $Y \subseteq \mathbb{R}^n$



$$\min_{x \in \mathbb{R}} f(x) = \min_{x \in \mathbb{R}} e^x$$

$$\text{Infimum de } f \text{ sur } Y \quad \inf_{y \in Y} f(y) \text{ tq } \begin{cases} \inf_{y \in Y} f(y) \leq f(x) \quad \forall x \in Y \\ \text{et} \\ \forall M > \inf_{y \in Y} f(y) \quad \exists x_0 \in Y \text{ tq } f(x_0) < M \end{cases}$$

Théorème de Weierstrass

Si l'infimum d'une fonction sur ensemble est atteint par au moins un point de l'ensemble alors il constitue un minimum global du problème d'optimisation correspondant



II) Fonction objectif

A) Convexité de la fonction objectif

Caractéristique très importante en optimisation



Pratiquement impossible d'identifier un optimum global pour une fonction non convexe !!!


Définition formelle

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ est **convexe**
si pour tout $x, y \in \mathbb{R}^n$ et pour tout $\lambda \in [0, 1]$, on a
 $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$




On parle de **convexité stricte** lorsque $f(\lambda x + (1-\lambda)y) < \lambda f(x) + (1-\lambda)f(y)$ pour tout $x \neq y$

Interprétation graphique (n=1)



convexe
Segment au dessus de la courbe de f entre x et y



La notion de concavité est rattachée à des problèmes de maximisation



II) Fonction objectif

B) Dérivabilité

1^{er} ordre

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ est une fonction continue

i^{ème} Dérivée partielle de f

$$\nabla_i f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial x_i} = \lim_{\alpha \rightarrow 0} \frac{f(x_1, x_2, \dots, x_i + \alpha, \dots, x_n) - f(x_1, x_2, \dots, x_i, \dots, x_n)}{\alpha}$$

Gradient de f (Cf cours Electromagnétisme ... 🤪) si les limites précédentes existent...

De façon plus générale si

$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ telle que $f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ est différentiable

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1(\mathbf{x})}{\partial x_1} & \frac{\partial f_2(\mathbf{x})}{\partial x_1} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_1(\mathbf{x})}{\partial x_n} & \frac{\partial f_2(\mathbf{x})}{\partial x_n} & \dots & \frac{\partial f_m(\mathbf{x})}{\partial x_n} \end{pmatrix}$$

Matrice gradient

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{pmatrix}$$



La matrice Jacobienne est définie par: $J(\mathbf{x}) = \nabla f(\mathbf{x})^T$



II) Fonction objectif

B) Dérivabilité

→ Dérivée directionnelle de f en x dans la direction $d \in \mathbb{R}^n$ ou dérivée de Gateaux

$$\lim_{\alpha \rightarrow 0} \frac{f(x + \alpha d) - f(x)}{\alpha} = \nabla f(x)^T d = d^T \nabla f(x)$$

I



Dérivée directionnelle pour $d=e_i \Leftrightarrow$ dérivée partielle $\nabla_i f(x)$

II

Si pour tout $d \in \mathbb{R}^n$, la dérivée directionnelle de f dans la direction d existe



f est différentiable ou Gateaux-différentiable

III

→ Direction de descente

Soient $\left\{ \begin{array}{l} f: \mathbb{R}^n \rightarrow \mathbb{R} \text{ une fonction différentiable} \\ x, d \in \mathbb{R}^n \end{array} \right.$

d est une direction de descente si $d^T \nabla f(x) < 0$

19



II) Fonction objectif

B) Dérivabilité

Parmi toutes les directions d à partir d'un point x , celle où la **descente est la plus forte** est la direction opposée au gradient de f

$$d \in \mathbb{R}^n \text{ tel que } \|d\| = \|\nabla f(x)\| \\ -\nabla f(x)^T \nabla f(x) \geq d^T \nabla f(x)$$

→ Convexité par le calcul du gradient

Soit $f: X \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction différentiable sur un ensemble convexe ouvert X

I

II

III


f est convexe sur X ssi $f(y) - f(x) \geq (y-x)^T \nabla f(x) \quad \forall x, y \in X$



$$f(y) \geq f(x) + (y-x)^T \nabla f(x) \quad \forall x, y \in X$$

Eq. hyperplan tangent à f en x

Une fonction f est convexe ssi son graphe se trouve au dessus des hyperplans tangents



20



II) Fonction objectif

B) Dérivabilité

→ 2nd ordre

→ j^{ème} Dérivée partielle de $\nabla_i f(\mathbf{x})$
(Cf cours Electromagnétisme ... 🤔 🤔)

$$\frac{\partial \nabla_i f(\mathbf{x})}{\partial x_j} = \frac{\partial \left(\frac{\partial f(\mathbf{x})}{\partial x_i} \right)}{\partial x_j} = \frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j}$$

→ Hessien de f

Les dérivées seconde précédentes sont regroupées dans la **matrice Hessienne** de f

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction 2 fois différentiable

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{pmatrix}$$

Matrice Hessienne



C'est le gradient de la matrice Jacobienne

21



II) Fonction objectif

B) Dérivabilité

→ Convexité par le calcul du hessien Comme le gradient, le hessien donne des informations sur la convexité éventuelle de f

Soit $f: X \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction 2 fois différentiable sur un ensemble convexe ouvert X

f est **convexe (resp. strictement convexe)** dans X si
 $\nabla^2 f(\mathbf{x})$ est semi définie positive (resp. définie positive) pour tout \mathbf{x} dans X

Matrice semi-définie positive

Matrice carrée $A \in \mathbb{R}^{n \times n}$ telle que $\mathbf{x}^T A \mathbf{x} \geq 0 \quad \forall \mathbf{x} \in \mathbb{R}^n$

Si A symétrique $\Rightarrow \lambda \geq 0$

Matrice définie positive

Matrice carrée $A \in \mathbb{R}^{n \times n}$ telle que $\mathbf{x}^T A \mathbf{x} > 0 \quad \forall \mathbf{x} \in \mathbb{R}^n, \mathbf{x} \neq 0$

Si A symétrique $\Rightarrow \lambda > 0$

Si A définie positive $\Rightarrow A^{-1}$ existe et est définie positive

22



II) Fonction objectif

B) Dérivabilité

→ Courbure

Dérivée seconde ↔ Information sur la courbure

Considérons $g: \mathbb{R} \rightarrow \mathbb{R}$ tq $g(\alpha) = f(\mathbf{x} + \alpha \mathbf{d})$

Dérivons 1 fois $g'(\alpha) = \mathbf{d}^T \nabla f(\mathbf{x} + \alpha \mathbf{d})$ ↔ $g'(\alpha=0)$ Dérivée directionnelle de f en \mathbf{x}

I Dérivons 2 fois $g''(\alpha) = \mathbf{d}^T \nabla^2 f(\mathbf{x} + \alpha \mathbf{d}) \mathbf{d}$ ↔ $g''(\alpha=0)$ Proportionnelle à la courbure de f en \mathbf{x}

II
III Normalisation pour éviter l'influence de la longueur de \mathbf{d} (en divisant par d^2)



Courbure de f en \mathbf{x} dans la direction \mathbf{d}

quotient de Rayleigh $\frac{\mathbf{d}^T \nabla^2 f(\mathbf{x}) \mathbf{d}}{\mathbf{d}^T \mathbf{d}}$



Courbure de f en $-\mathbf{d}$ est identique à la courbure de f en \mathbf{d}

23



II) Fonction objectif




B) Dérivabilité



Soit $f(\mathbf{x}) = \frac{1}{2}x_1^2 + 2x_2^2$

Calculer les dérivées directionnelles et la courbure de f au point $(1 \ 1)^T$ dans chacune des directions suivantes :

$\mathbf{d}_1 = -\nabla f(\mathbf{x})$, $\mathbf{d}_2 = (-1 \ -1)^T$, $\mathbf{d}_3 = (1 \ -3)^T$



$f(\mathbf{x} + \alpha \mathbf{d}_i)$ ne diminue pas continuellement !!!

Propriété de descente est locale



On peut vérifier que la fonction est convexe sur un intervalle donné

24



II) Fonction objectif

C) Linéarité et non linéarité

→ Fonction linéaire

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ linéaire si elle s'écrit
 $f(x) = c^T x$ où $c \in \mathbb{R}^n$ constant

$f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ linéaire si chacune de ces composantes
 $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ est linéaire
 $f(x) = Ax$ où $A \in \mathbb{R}^{m \times n}$ constant

→ Fonction affine

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ Affine si elle s'écrit
 $f(x) = c^T x + d$ où $c \in \mathbb{R}^n, d \in \mathbb{R}$ constant

$f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ affine si chacune de ces composantes
 $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ est affine
 $f(x) = Ax + b$ où $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$ constant

25



II) Fonction objectif


C) Linéarité et non linéarité

→ Fonction non linéaire

Toute fonction qui n'est pas affine est non linéaire

→ Définition

La continuité du gradient au sens de Lipschitz permet de quantifier le « degré » de non linéarité.



Soit $f : X \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$. La matrice gradient est continue au sens de Lipschitz sur X si
 $\exists M$ tq $\|\nabla f(x) - \nabla f(y)\|_n \leq M \|x - y\|_n$ pour tout $x, y \in X$

- M correspond à une borne supérieure de la courbure
- M est appelé constante de Lipschitz
- $M = 0 \iff \nabla f$ constant sur $X \iff f$ linéaire
- M constante théorique très difficile à calculer

Norme vectorielle

La norme-p de x est définie par la fonction $\|\cdot\|_p : \mathbb{R}^n \rightarrow \mathbb{R}$ telle que

$$\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p} \quad x \in \mathbb{R}^n$$

26



II) Fonction objectif

C) Linéarité et non linéarité

→ Cas particulier : fonction quadratique

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sera dite **quadratique** si elle peut s'écrire

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

\mathbf{Q} matrice symétrique de $n \times n$
 $c \in \mathbb{R}$, $\mathbf{b} \in \mathbb{R}^n$

I

II

III

→ $\nabla f(\mathbf{x}) = \mathbf{Q}\mathbf{x} + \mathbf{b}$

→ $\nabla^2 f(\mathbf{x}) = \mathbf{Q}$



Le facteur $\frac{1}{2}$ sert seulement à simplifier les écritures du gradient



Exemple de fonction quadratique définie par : $\mathbf{Q} = \begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix}$ et $\mathbf{b} = (1 \ 0)^T$ et $c = -4$

Donner l'expression analytique de : $f(x, y)$



27



II) Fonction objectif

D) Conditionnement

Conditionnement de f en \mathbf{x} **=** Nombre de conditionnement de la matrice $\nabla^2 f(\mathbf{x})$

→ Définition formelle

Soit $\mathbf{A} \in \mathbb{R}^{n \times n}$ matrice symétrique non singulière

I

II

III

Nb de conditionnement de \mathbf{A} $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$

si norme-2 euclidienne

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \frac{\sigma_1}{\sigma_n}$$



Si \mathbf{A} est symétrique semi définie positive alors $\sigma_i = \lambda_i$

Matrice singulière

Matrice singulière \mathbf{A} telle que $\det(\mathbf{A}) = 0$

Matrice non singulière = matrice inversible ou régulière

Valeurs/vecteurs propres

valeurs propres λ_i de $\mathbf{A} \in \mathbb{R}^{n \times n}$

racines du polynôme caractéristique $\det(\lambda \mathbf{I} - \mathbf{A}) = 0$

vecteurs propres \mathbf{x} tq : $\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$

Valeurs singulières

valeurs singulières σ_i de $\mathbf{A} \in \mathbb{R}^{m \times n}$

si il existe 2 matrices orthogonales

$\mathbf{U} \in \mathbb{R}^{m \times m}$ et $\mathbf{V} \in \mathbb{R}^{n \times n}$ tel que :

$\mathbf{U}^T \mathbf{A} \mathbf{V} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$

avec $p = \min(m, n)$ et $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p$

28



II) Fonction objectif

D) Conditionnement

Théorème de Rayleigh-Ritz

$$A \in \mathbb{R}^{n \times n} \text{ matrice réelle symétrique}$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \text{ vp de } A$$

$$\lambda_1 = \max_{x \neq 0} \frac{x^T A x}{x^T x} \text{ et } \lambda_n = \min_{x \neq 0} \frac{x^T A x}{x^T x}$$


Interprétation géométrique

Soit $f: \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction non linéaire et $x \in \mathbb{R}^n$

Supposons la matrice $\nabla^2 f(x)$ (forcement symétrique) définie positive

λ_1 la plus grande vp $\Rightarrow Ad_1 = \lambda_1 d_1$ $\xrightarrow{\text{normalisation } d_1^T \times}$ $\lambda_1 = \frac{d_1^T A d_1}{d_1^T d_1}$ $\xrightarrow{\text{Théorème de Rayleigh-Ritz}}$ + grande courbure est dans la direction d_1

λ_n la plus petite vp $\Rightarrow Ad_n = \lambda_n d_n$ $\xrightarrow{\text{normalisation } d_n^T \times}$ $\lambda_n = \frac{d_n^T A d_n}{d_n^T d_n}$ $\xrightarrow{\text{Théorème de Rayleigh-Ritz}}$ + petite courbure est dans la direction d_n



II) Fonction objectif

D) Conditionnement

\Rightarrow Changement de variable
Permet la diminution du conditionnement

$$x' = Mx$$

M : matrice inversible
 $x \in \mathbb{R}^n$

$$\tilde{f}(x') = f(M^{-1}x') = f(x) \Rightarrow \nabla \tilde{f}(x') = M^{-T} \nabla f(M^{-1}x')$$

$$\nabla^2 \tilde{f}(x') = M^{-T} \nabla^2 f(M^{-1}x') M^{-1} = M^{-T} \nabla^2 f(x) M^{-1}$$

Conditionnement de \tilde{f} en x' est le nb de conditionnement de la matrice $\nabla^2 \tilde{f}(x')$ soit $M^{-T} \nabla^2 f(x) M^{-1}$

Choisir M tq le conditionnement le plus proche possible de 1

préconditionnement



Le meilleur conditionnement possible ($\kappa_2 = 1$) est obtenu en effectuant le changement de variable sur la base de la factorisation de Cholesky de la matrice $\nabla^2 f(x)$ soit $M = L^T$

Décomposition de Cholesky

Soit $A \in \mathbb{R}^{n \times n}$
matrice symétrique définie positive
Décomposition de A tq : $A = LL^T$
 $L \in \mathbb{R}^{n \times n}$: matrice triangulaire inférieure

$$\text{Soit } f(x) = \frac{1}{2}x_1^2 + \frac{25}{2}x_2^2 + 3x_1x_2 - 12x_1 - \sqrt{\pi}x_2 - 6$$

Transformer f de façon à obtenir un conditionnement de 1



III) Les contraintes ...

A) Contraintes actives

→ Définition formelle


Soient $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$ et $h: \mathbb{R}^n \rightarrow \mathbb{R}^m$

une contrainte d'inégalité $g_i(x) \leq 0$ est dite **active** en x^* si $g_i(x^*) = 0$ pour $i=1, \dots, p$
est dite **inactive** en x^* si $g_i(x^*) < 0$ pour $i=1, \dots, p$
une contrainte d'égalité $h_i(x) = 0$ est dite **active** en x^* si $h_i(x^*) = 0$ pour $i=1, \dots, m$
L'ensemble des indices i des contraintes actives en x^* est noté $A(x^*)$

→ Interprétation géométrique

Soit le problème d'optimisation $\min_{x \in \mathbb{R}} x^2$ sous contraintes:

$x \leq 4 \iff g_1(x) = x - 4 \leq 0$
 $x \geq -10 \iff g_2(x) = -x - 10 \leq 0$
sol : $x^* = 0$ $g_1(x^*) = -4 < 0$ et $g_2(x^*) = -10 < 0$
Possibilité d'ignorer les contraintes sans incidence
 $x \leq 4 \iff g_1(x) = x - 4 \leq 0$
 $x \geq 1 \iff g_2(x) = 1 - x \leq 0$
sol : $x^* = 1$ $g_1(x^*) = -3 < 0$ et $g_2(x^*) = 0$
Seul g_1 peut être ignorée sans incidence



III) Les contraintes ...

A) Contraintes actives

→ Théorème des contraintes actives

Permet de supprimer les contraintes inactives

Réduire les contraintes du problème

Soit $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ une fonction non linéaire et x^* un point admissible

x^* est un minimum local du problème

$\min_{x \in \mathbb{R}^n} f(x)$
sous contraintes
 $g(x) \leq 0$
 $x \in Y \subseteq \mathbb{R}^n$

ssi

x^* est un minimum local du problème

$\min_{x \in \mathbb{R}^n} f(x)$
sous contraintes
 $g_i(x) = 0$ pour $i \in A(x^*)$
 $x \in Y \subseteq \mathbb{R}^n$ $A(x^*)$: Ensemble des indices des contraintes actives en x^*



Intérêt limité car il faudrait connaître la solution x^* !!!



III) Les contraintes ...

B) Gestion des contraintes

Gestion des contraintes dans les algorithmes \longleftrightarrow complexe !!!

→ Hypothèses nécessaires : Indépendance linéaire
Etc ...

→ Nombreuses méthodes :

➤ Elimination des contraintes redondantes

➤ Pb d'optimisation avec contraintes \longrightarrow Pb d'optimisation sans contraintes
+ simple à résoudre

Limites du cours : Optimisation sans contraintes



La gestion des contraintes dans le cadre de l'optimisation combinatoire fait l'objet du cours « programmation par contraintes » du bloc option Fi-OptMath 1

33

