

Chapitre 3

Problèmes quadratiques
Méthodes de Newton locales
Méthodes de descente de gradient
Méthodes quasi-Newton

Méthodes d'optimisation sans contrainte

III

1

I) Problèmes quadratiques

A) Méthode directe

Considérons le problème d'optimisation suivant :
(Cf cours Chap 1 T26 et Chap 2 T4)

$\mathbf{b} \in \mathbb{R}^n, c \in \mathbb{R} \quad \mathbf{Q} \in \mathbb{R}^{n \times n}$ matrice symétrique
définie positive

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

Unique minimum global



$= -\mathbf{b}$



Résolution classique
(méthode d'algèbre linéaire)

Configuration initiale

Calculer factorisation de Cholesky de Q
 $\mathbf{Q} = \mathbf{L}\mathbf{L}^T$

Calculer \mathbf{y}^* tq : $\mathbf{L}\mathbf{y} = -\mathbf{b}$

Calculer \mathbf{x}^* tq : $\mathbf{L}^T \mathbf{x} = \mathbf{y}$

STOP \mathbf{x}^*

solution
exacte \mathbf{x}^*

Matrice $\mathbf{Q} \in \mathbb{R}^{n \times n}$ matrice symétrique
Vecteur $\mathbf{b} \in \mathbb{R}^n$ définie positive



Cette résolution typique nécessite
que f soit quadratique au sens strict;
ce qui n'est pas toujours le cas ...

2

I) Problèmes quadratiques

B) Méthode des gradients conjugués Hestenes et Stiefel (1952)

→ Directions conjuguées

$Q \in \mathbb{R}^{n \times n}$ matrice définie positive

Les vecteurs $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_k$ non nuls de \mathbb{R}^n sont dits Q-conjugués si

$$\mathbf{d}_i^T Q \mathbf{d}_j = 0 \quad \forall i, j \text{ tq } i \neq j$$

I

II

III

$\Leftrightarrow \mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_k$ linéairement indépendants

\Leftrightarrow Nombre maximal de direction conjuguées = n



Si $Q=I$ les directions conjuguées sont orthogonales

3

I) Problèmes quadratiques

B) Méthode des gradients conjugués

→ Principe de la méthode

Utilisation de n directions Q-conjuguées $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_n$ dans un algorithme basée sur la récurrence suivante :

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k \quad \text{avec} \quad \alpha_k = \arg \min_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{d}_k)$$

$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{n+1}$: les itérés générés par une méthode de directions conjuguées

I

II

III

→ Propriétés:

→ pour tout $k=1, \dots, n$, le pas α_k est défini par

$$\alpha_k = -\frac{\mathbf{d}_k^T (Q\mathbf{x}_k + \mathbf{b})}{\mathbf{d}_k^T Q \mathbf{d}_k} = -\frac{\mathbf{d}_k^T \nabla f(\mathbf{x}_k)}{\mathbf{d}_k^T Q \mathbf{d}_k}$$

→ pour tout $k=1, \dots, n$, $\nabla f(\mathbf{x}_k)$ est orthogonal à $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_{k-1}$


$$\nabla f(\mathbf{x}_k)^T \mathbf{d}_i = 0 \quad \text{pour } i = 1, \dots, k-1$$

→ $\nabla f(\mathbf{x}_{n+1}) = 0$

→ soit k tq $\nabla f(\mathbf{x}_k) = 0 \Rightarrow \nabla f(\mathbf{x}_i) = 0$ pour $i = k, \dots, n+1$

→ Identification du min global en au plus n itérations

Résolution successives dans des sous espaces vectoriels de dimension croissante engendrés par $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_i$ ($i \leq n$)

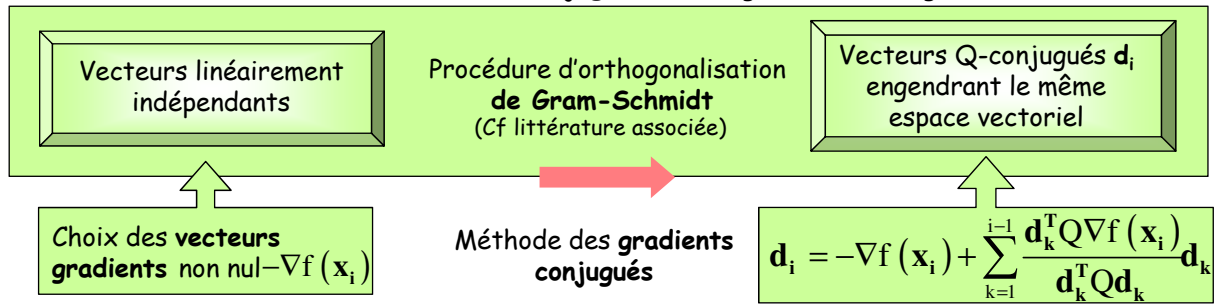


4

I) Problèmes quadratiques

B) Méthode des gradients conjugués

→ **Détermination des directions conjugués** (Analogie avec l'orthogonalité)



Les vecteurs gradients sont non seulement indépendants mais ... tous orthogonaux:

$$\nabla f(x_i)^T \nabla f(x_k) = 0 \text{ pour } k = 1, \dots, i-1$$

→ Expression de d_i en fonction de d_{i-1}

$$d_i = -\nabla f(x_i) + \beta_i d_{i-1} \quad \text{avec} \quad \beta_i = \frac{\nabla f(x_i)^T \nabla f(x_i)}{\nabla f(x_{i-1})^T \nabla f(x_{i-1})} = \frac{(Qx_i + b)^T (Qx_i + b)}{(Qx_{i-1} + b)^T (Qx_{i-1} + b)}$$

5

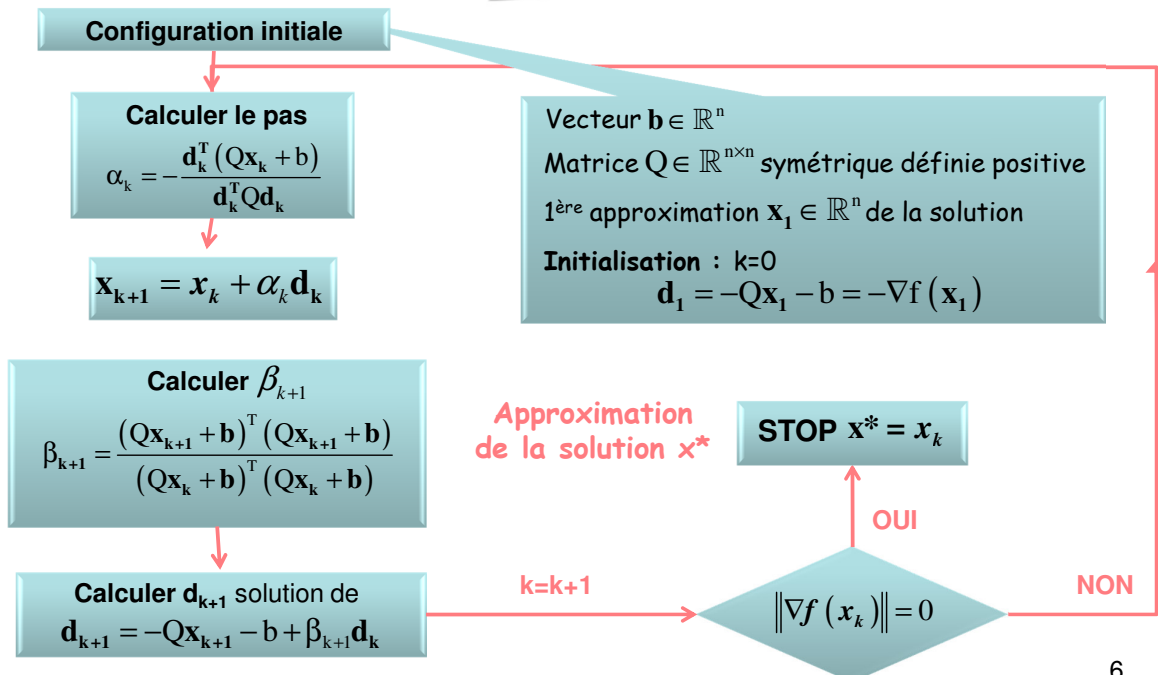
I) Problèmes quadratiques

B) Méthode des gradients conjugués

→ **Algorithme**



Le critère d'arrêt peut également être: $k=n+1$



6

II) Méthode de Newton locale

A) Méthode de Newton linéaire

Utilisation de l'algorithme de Newton (cf chap 2 T12)

Résoudre les conditions nécessaires d'optimalité

Trouver une approximation de la solution de l'équation $\nabla f(\mathbf{x}) = 0$

Algorithme

Configuration initiale

Gradient de f $\nabla f : \mathbb{R}^n \rightarrow \mathbb{R}^n$

Hessien de f $\nabla^2 f : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$

1^{ère} approximation $\mathbf{x}_0 \in \mathbb{R}^n$ de la solution

Précision demandée: $\varepsilon \in \mathbb{R}^n, \varepsilon > 0$

Initialisation : $k=0$

Calculer \mathbf{d}_{k+1} solution de $\nabla^2 f(\mathbf{x}_k) \mathbf{d}_k = -\nabla f(\mathbf{x}_k)$

$\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k$

$\|\nabla f(\mathbf{x}_k)\| \leq \varepsilon$

NON

OUI

STOP $\mathbf{x} \approx \mathbf{x}_k$

Approximation de la solution \mathbf{x}^*

7

II) Méthode de Newton locale

A) Méthode de Newton linéaire

Avantages / Inconvénients

➤ Méthode converge q-quadratiquement dans les conditions favorables (cf chap 2 T10)

➤ Peut diverger si le point de départ est trop éloigné de la solution

➤ Méthode non définie si $\nabla^2 f(\mathbf{x}_k)$ non inversible ➔ Solution : rendre inversible cette matrice

➤ Aucun mécanisme permettant de discerner les minima, des maxima et points selles...

Globalement, ne peut être utilisée telle quelle dans les problème d'optimisation

Cas favorables

Mise à profit de sa grande efficacité et rapidité de convergence lorsque le cas est adéquat

Méthode de Newton quadratique (cf T9)

Autres cas...

Utilisation de méthodes alternatives

Méthode de Newton avec recherche linéaire (cf T20)

8

II) Méthode de Newton locale

B) Méthode de Newton quadratique

Idée de base de la méthode de Newton

Remplacer une fonction non linéaire par un modèle plus simple



Par exemple linéaire (cf Chap 2 T6)

Modèle quadratique

Application de la formule de Taylor sur une fonction non linéaire

Fonction à plusieurs variables Soit une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ deux fois différentiable (cf Chap 2 T6)

Modèle quadratique de f en $\hat{\mathbf{x}}$ est noté $m_{\hat{\mathbf{x}}}(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ défini par :

$$m_{\hat{\mathbf{x}}}(\mathbf{x}) = f(\hat{\mathbf{x}}) + (\mathbf{x} - \hat{\mathbf{x}})^T \nabla f(\hat{\mathbf{x}}) + \frac{1}{2} (\mathbf{x} - \hat{\mathbf{x}})^T \nabla^2 f(\hat{\mathbf{x}}) (\mathbf{x} - \hat{\mathbf{x}}) \quad \text{En posant : } \mathbf{d} = \mathbf{x} - \hat{\mathbf{x}}$$

$$m_{\hat{\mathbf{x}}}(\hat{\mathbf{x}} + \mathbf{d}) = f(\hat{\mathbf{x}}) + \mathbf{d}^T \nabla f(\hat{\mathbf{x}}) + \frac{1}{2} \mathbf{d}^T \nabla^2 f(\hat{\mathbf{x}}) \mathbf{d}$$



On retrouve bien la définition d'une forme quadratique (cf chap1 T26) avec $Q = \nabla^2 f(\hat{\mathbf{x}})$, $\mathbf{b} = \nabla f(\hat{\mathbf{x}})$ et $c = f(\hat{\mathbf{x}})$

9

II) Méthode de Newton locale

B) Méthode de Newton quadratique

Principe

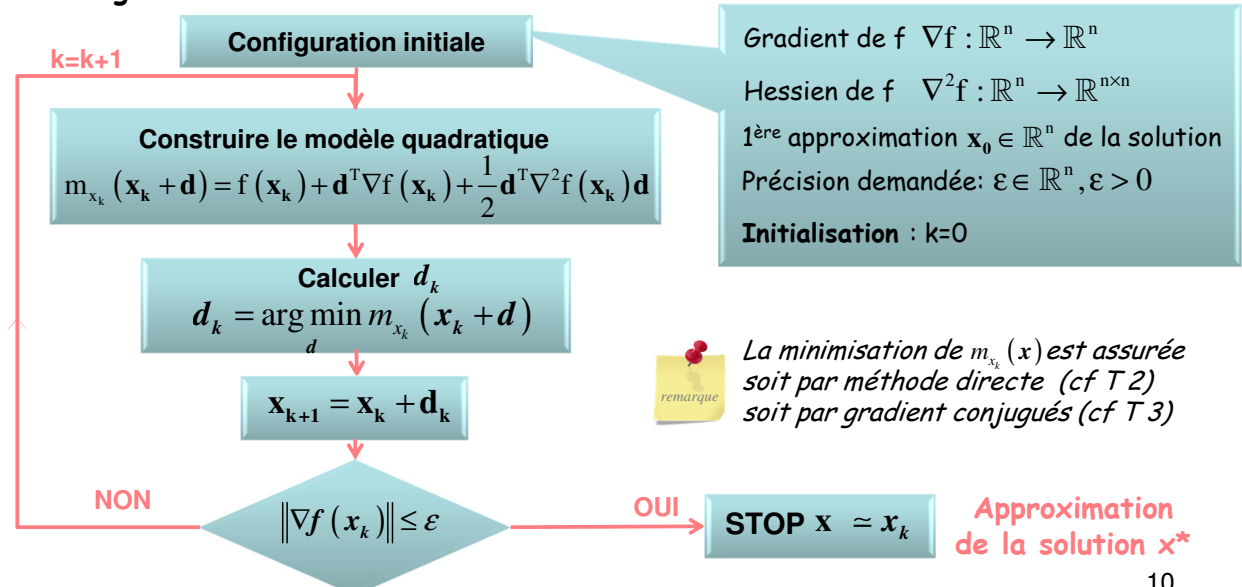
Modélisation quadratique de la fonction objectif en \mathbf{x}_k



Condition favorable pour l'efficacité de la méthode de Newton

$\nabla^2 f(\mathbf{x})$ doit forcément être définie positive pour pouvoir appliquer la méthode

Algorithme




10

II) Méthode de Newton locale

B) Méthode de Newton quadratique


Limitation



$$\rightarrow f(x_{k+1}) > f(x_k)$$

Nouveau point généré est moins bon que le précédent !!!

Méthode efficace si la fonction est par nature très proche d'une forme quadratique et convexe



$$\rightarrow f(x_{k+1}) > f(x_k)$$

Effet inverse !!! maximisation

Modèle concave non borné

11

II) Méthode de Newton locale

C) Points particuliers

Soit une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ deux fois différentiable et soit $x_k \in \mathbb{R}^n$

Point de Newton



Point obtenu lors d'une itération de la méthode de Newton locale

Point qui minimise le modèle quadratique de la fonction en x_k

si $\nabla^2 f(x_k)$ est définie positive, le point de Newton de f en x_k est le point :

$$x_N = x_k + d_N \quad \text{où } d_N \text{ est la solution du système de Newton suivant: } \nabla^2 f(x_k) d_N = -\nabla f(x_k)$$

Point de Cauchy

Point qui minimise le modèle quadratique dans la direction de la plus forte pente

Le point de Cauchy de f en x_k est le point: $x_C = x_k - \alpha_C \nabla f(x_k)$ où $\alpha_C = \arg \min_{\alpha \in \mathbb{R}_0^+} m_{x_k}(x_k - \alpha \nabla f(x_k))$

Si f est convexe dans la direction du gradient, on a (cf T9):

$$\alpha_C = \frac{\nabla f(x_k)^T \nabla f(x_k)}{\nabla f(x_k)^T \nabla^2 f(x_k) \nabla f(x_k)}$$

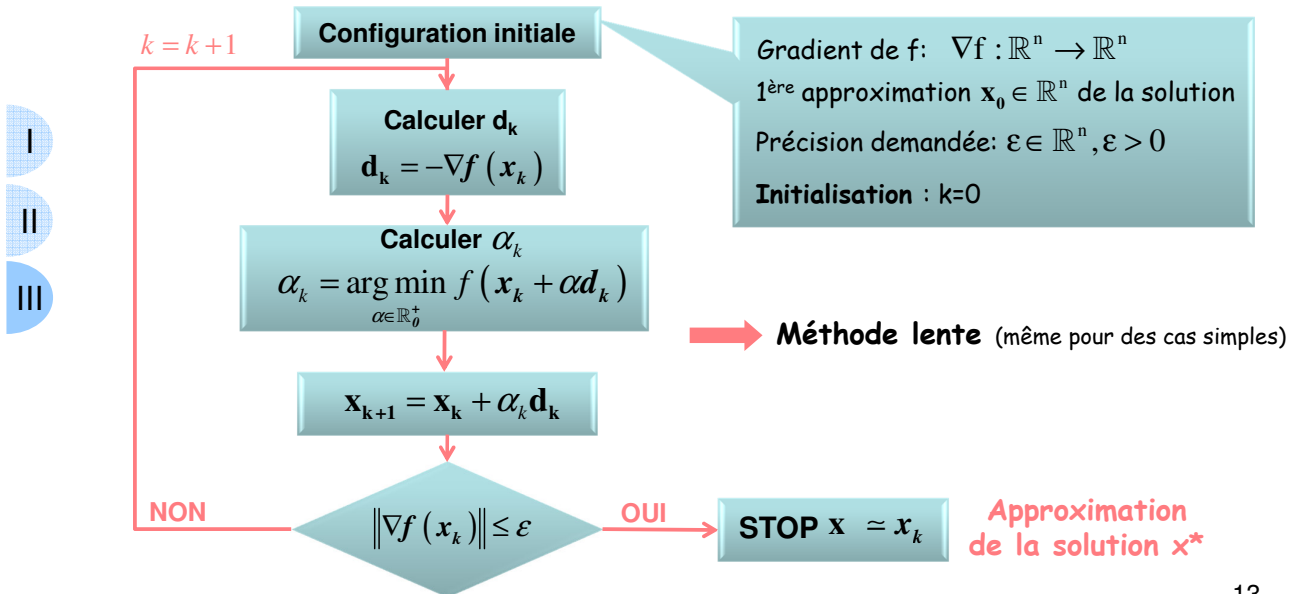
12

III) Méthode de la plus forte pente

A) Principe de la méthode

Idée de base des méthodes de descente

Suivre la direction de la plus forte pente donnée par la direction opposée au gradient
(Cf chap 1 T19)



13

III) Méthode de la plus forte pente

B) Préconditionnement

Réduction du conditionnement
(cf Chap 1 T27)



Amélioration des performances de l'algorithme des plus fortes pentes

Modification de la direction de descente

Soit H_k une matrice symétrique définie positive telle que : $H_k = L_k L_k^T$

définissant le **changement de variable** pour l'itération k : $\mathbf{x}' = L_k^T \mathbf{x}$



Ici, H_k n'est pas forcément la matrice Hessienne mais une matrice permettant la réduction de κ_2

Ecriture de la méthode des plus fortes pentes

sur les variables \mathbf{x}' : $\mathbf{x}'_{k+1} = \mathbf{x}'_k - \alpha_k \nabla f(\mathbf{x}'_k)$

sur les variables \mathbf{x} : $\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k H_k^{-1} \nabla f(\mathbf{x}_k)$

on pose

$$D_k = H_k^{-1}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k D_k \nabla f(\mathbf{x}_k)$$

Direction de descente à chaque itération:

$$\mathbf{d}_k = -D_k \nabla f(\mathbf{x}_k)$$



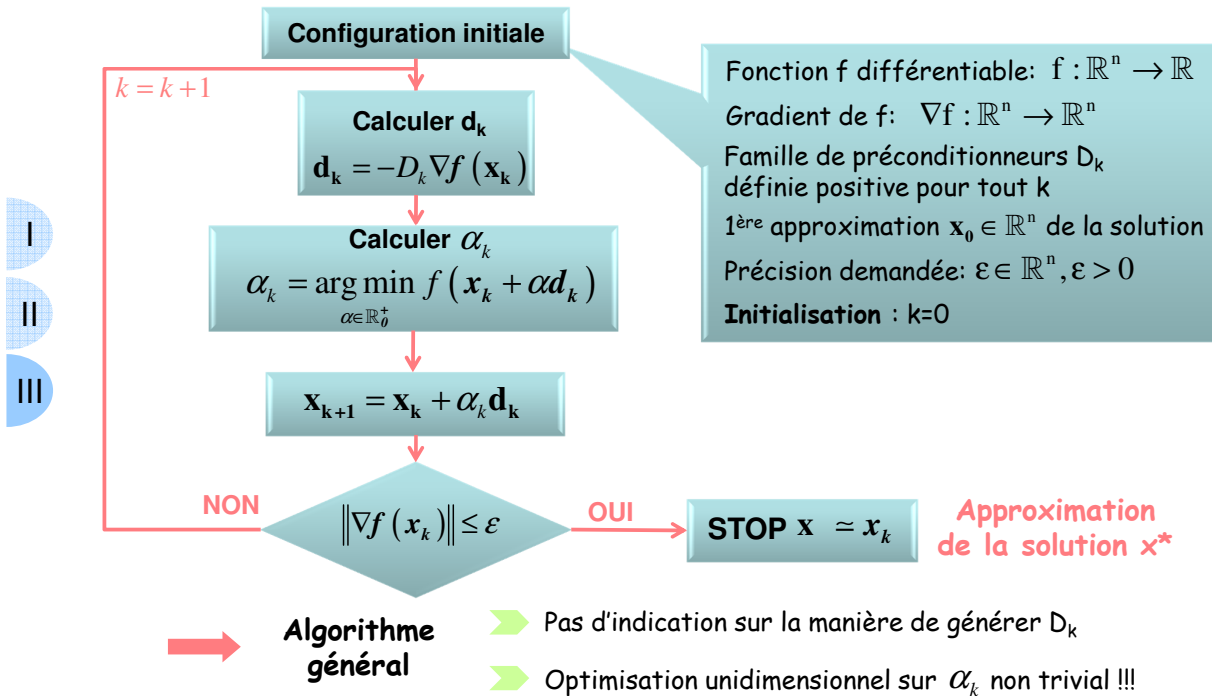
D_k permet de preconditionner différemment à chaque itération k

14

III) Méthode de la plus forte pente

B) Préconditionnement

Algorithme avec preconditionnement



15

III) Méthode de la plus forte pente

B) Préconditionnement

Exemple

Minimum de la fonction $f(x) = \frac{1}{2}x_1 + \frac{9}{2}x_2$

Descente en « zig zag »
caractéristique de la méthode

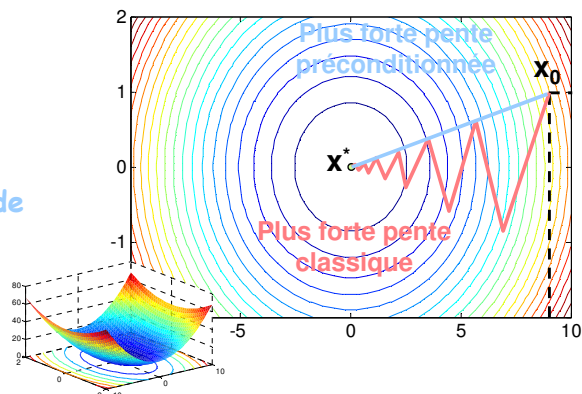


Lenteur désastreuse !!!

Préconditionnement par factorisation de Cholesky de la matrice Hessienne



Le minimum est atteint au bout ...d'une seule itération !!!




Amélioration significative lorsque la fonction
objectif est preconditionnée

16

III) Méthode de la plus forte pente

C) Choix du pas



I $\rightarrow \alpha_k$ pas trop grand

Eviter la disproportion entre la longueur du pas et la diminution de la fonction objectif résultante

II Notion de « Diminution suffisante »

III Diminution jugée suffisante si proportionnelle au pas


$$\gamma = -\beta_1 \nabla f(x_k)^T d_k$$

$$0 < \beta_1 < 1$$

$$f(x_k) - f(x_k + \alpha_k d_k) \geq \alpha_k \gamma$$

1^{ère} condition de Wolfe (CW1)

$$f(x_k + \alpha_k d_k) \leq f(x_k) - \alpha_k \gamma$$



Choix de γ en fonction de la pente en x_k dans la direction d_k

Diminution jugée suffisante pour $\alpha < 2$

17

III) Méthode de la plus forte pente

C) Choix du pas

$\rightarrow \alpha_k$ pas trop petit

Eviter la dégénérescence des pas α_k vers 0

Notion de « progrès suffisant »


Progrès suffisant si dérivée directionnelle au point $x_k + \alpha_k d_k$ augmente par rapport à celle évaluée point x_k

$$\nabla f(x_k + \alpha_k d_k)^T d_k \geq \beta_2 \nabla f(x_k)^T d_k \quad \text{avec} \quad \nabla f(x_k)^T d_k < 0$$

$$\frac{\nabla f(x_k + \alpha_k d_k)^T d_k}{\nabla f(x_k)^T d_k} \leq \beta_2$$

$$0 < \beta_2 < 1$$

2^{de} condition de Wolfe (CW2)



Progrès jugé suffisante pour $\alpha \geq 2,4$



Ces conditions portent également de nom de condition d'Armijo-Goldstein

La validité des conditions de Wolfe impose que:

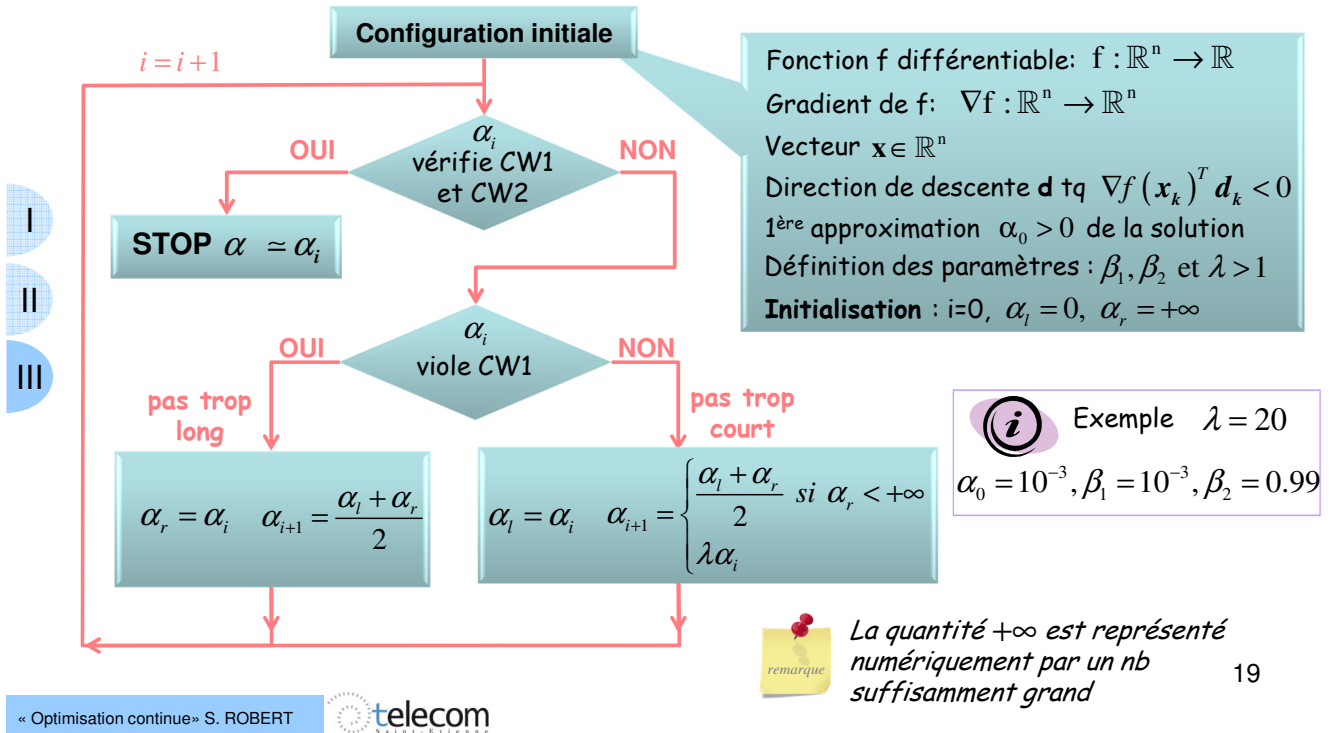
$$0 < \beta_1 < \beta_2 < 1$$

18

III) Méthode de la plus forte pente

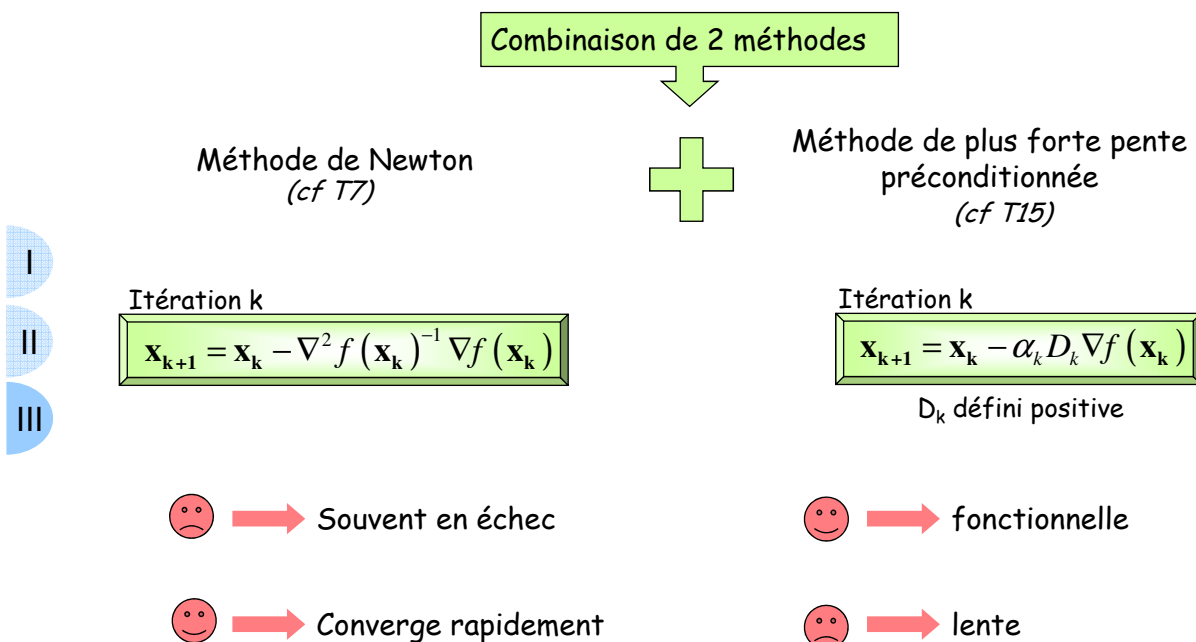
C) Choix du pas

➔ **Algorithme de Fletcher et Lemaréchal (FL)** Recherche linéaire du pas qui vérifie les conditions de Wolfe



IV) Méthode de Newton avec recherche linéaire

A) Principe général



IV) Méthode de Newton avec recherche linéaire

A) Principe général

Application de l'itération de la méthode des plus fortes pentes préconditionnée

➤ Si $\begin{cases} \nabla^2 f(x_k) \text{ est défini positif} \\ \alpha_k = 1 \text{ vérifie les CW} \end{cases} \rightarrow \text{Itérations équivalentes}$

$$D_k = \nabla^2 f(x_k)^{-1}$$

I ➤ Si $\alpha_k = 1$ ne vérifie les CW \rightarrow Trouver un autre pas

Application de l'algorithme de Fletcher et Lemaréchal (FL)

II ➤ Si $\nabla^2 f(x_k)$ n'est pas défini positif \rightarrow Trouver un autre préconditionneur

Plusieurs méthodes...



Exemple

$$D_k \text{ diagonale avec pour élément } (i,i) \quad \max \left(\varepsilon, \left(\frac{\partial^2 f}{\partial x_i^2}(x_k) \right)^{-1} \right)$$

avec $\varepsilon > 0$ pour garantir l'aspect définie positive

21

IV) Méthode de Newton avec recherche linéaire

B) Méthode complète

➤ Principe

Application de l'itération de la méthode des plus fortes pentes préconditionnée



Il existe toujours un τ tel que D_k soit définie positive

Choix du préconditionneur

Modifier la matrice Hessienne afin de la rendre définie positive

$$D_k = (\nabla^2 f(x_k) + \tau I)^{-1}$$

➤ Recherche de τ par une méthode simple

Permettant également la factorisation de Cholesky modifiée de $\nabla^2 f(x_k) + \tau I$

Configuration initiale

Factorisation de Cholesky LL^T de $H + \tau_k I$

factorisation réussie ?

STOP L et τ

OUI

NON

$$\tau_{k+1} = \max \left(2\tau_k, \frac{1}{2} \|H\|_F \right)$$

$k = k + 1$

Norme de Frobenius

$$A \in \mathbb{R}^{m \times n} \quad \|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}$$

Matrice symétrique $H \in \mathbb{R}^{n \times n}$

Initialisation : $k=0$,
si $\min h_{ii} > 0$ alors $\tau_0 = 0$
sinon $\tau_0 = \|H\|_F$

22

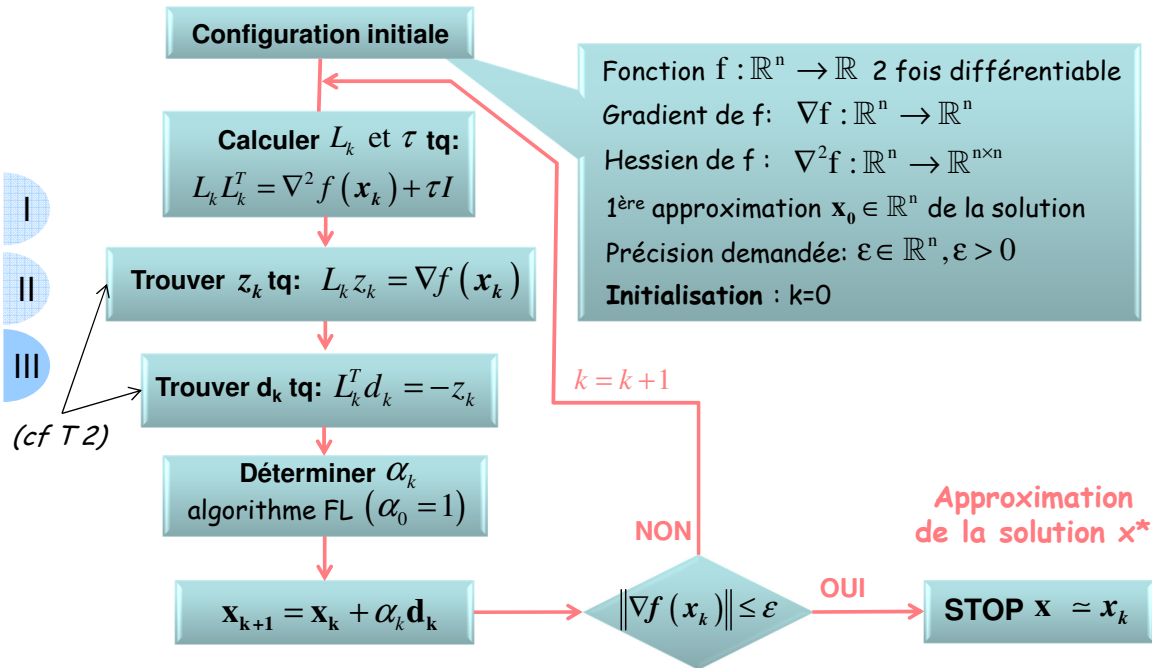
IV) Méthode de Newton avec recherche linéaire

B) Méthode complète

Algorithme



Lorsque cette méthode est appliquée sur un problème de moindres carrés, elle porte le nom de **Levenberg Marquardt**



23

IV) Méthode de Newton avec recherche linéaire

C) Convergence

Convergence de la méthode de Newton

Dépendance du point de départ
 Plus la fonction est non linéaire plus x_0 doit être proche de la solution
 (cf chapitre 2 T11)

Intérêt de la méthode de Newton avec recherche linéaire

Convergence quelque soit le point de départ

Convergence globale

Soit un algorithme itératif qui génère une suite $(x_k)_k$ dans \mathbb{R}^n , afin de résoudre le problème de minimisation sans contrainte :

$$\min_{x \in \mathbb{R}^n} f(x)$$

avec $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continûment différentiable.

L'algorithme est dit globalement convergent si:

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0 \quad \forall x_0 \in \mathbb{R}^n$$

24

IV) Méthode de Newton avec recherche linéaire

C) Convergence



Attention à ne pas confondre « convergence globale » avec « minimum global »

Convergence globale
Pour un algorithme utilisant méthode de Newton avec recherche linéaire

Directions de descente de plus en plus orthogonales à la direction du gradient
(non démontré ici)

Pour garantir : $\lim_k \nabla f(\mathbf{x}_k)^T \mathbf{d}_k < 0$

$$\cos \theta_k = \frac{\nabla f(\mathbf{x}_k)^T \mathbf{d}_k}{\|\nabla f(\mathbf{x}_k)\| \|\mathbf{d}_k\|}$$

ne peut pas tendre vers 0 !!!

$\cos \theta_k$ est borné par une constante strictement positive



Les directions \mathbf{d}_k ne dégénèrent pas en devenant asymptotiquement orthogonales au gradient

On dit que la suite $(\mathbf{d}_k)_k$ doit être en **relation gradient** avec $(\mathbf{x}_k)_k$ pour assurer la **convergence globale**

25

V) Méthodes de Quasi-Newton

A) Principe

Même principe que pour la résolution numérique des équations non linéaires
(cf chapitre 2 T16)

Méthode de Newton
(locale et avec recherche linéaire)

Calcul de matrice Hessienne

En pratique:

➤ Calcul analytique et implémentation fastidieux

➔ Sujet à erreurs

➤ Consomme beaucoup de temps de calcul

➔ Pénalise l'efficacité de la méthode

Inspiration directe des méthodes sécantes appliquées au modèle quadratique

$$\mathbf{H}_k \mathbf{d}_{k-1} = \mathbf{y}_{k-1} \quad \text{avec} \\ \mathbf{y}_{k-1} = \nabla f(\mathbf{x}_k) - \nabla f(\mathbf{x}_{k-1})$$

Mise à jour de Broyden de la matrice Hessienne
(cf chapitre 2 T20)



Problème !!!

$\nabla^2 f(\mathbf{x}_k)$ pas forcément symétrique ni définie positive

Condition nécessaire pour calculer \mathbf{d}_k
(cf T10)

26

V) Méthodes de Quasi-Newton

B) Méthode BFGS

Modification de la mise à jour de Broyden

BUT: obtenir $H_k = A_k A_k^T$
symétrique positive vérifiant l'équation sécante $\rightarrow A_k A_k^T d_{k-1} = y_{k-1}$



L'équation sécante définie positive possède une solution ssi $d_{k-1}^T y_{k-1} > 0$

Soit une fonction $f: \mathbb{R}^n \rightarrow \mathbb{R}$ différentiable et 2 itérés x_k et x_{k-1} tq $d_{k-1}^T y_{k-1} > 0$

avec $d_{k-1} = x_k - x_{k-1}$ et $y_{k-1} = \nabla f(x_k) - \nabla f(x_{k-1})$

Soit une matrice symétrique définie positive $H_{k-1} \in \mathbb{R}^{n \times n}$

La mise à jour de C.G. Broyden, D. Goldfarb et D.F. Shanno (BFGS) est définie par:

$$H_k = H_{k-1} + \frac{y_{k-1} y_{k-1}^T}{y_{k-1}^T d_{k-1}} - \frac{H_{k-1} d_{k-1} d_{k-1}^T H_{k-1}}{d_{k-1}^T H_{k-1} d_{k-1}}$$

27

V) Méthodes de Quasi-Newton

B) Méthode BFGS

Algorithme

Reprendre algorithme de Newton avec recherche linéaire (Cf T23)

Remplacement de la matrice Hessienne par son approximation BFGS $\nabla^2 f(x_k) \iff H_k$

H_k forcément définie positive \iff Simplification de l'algorithme pour la recherche de d_k

$$H_k d_k = -\nabla f(x_k)$$

Résolution du système sur d_k fastidieux et coûteux en calcul \iff Calcul analytique de H_k^{-1}

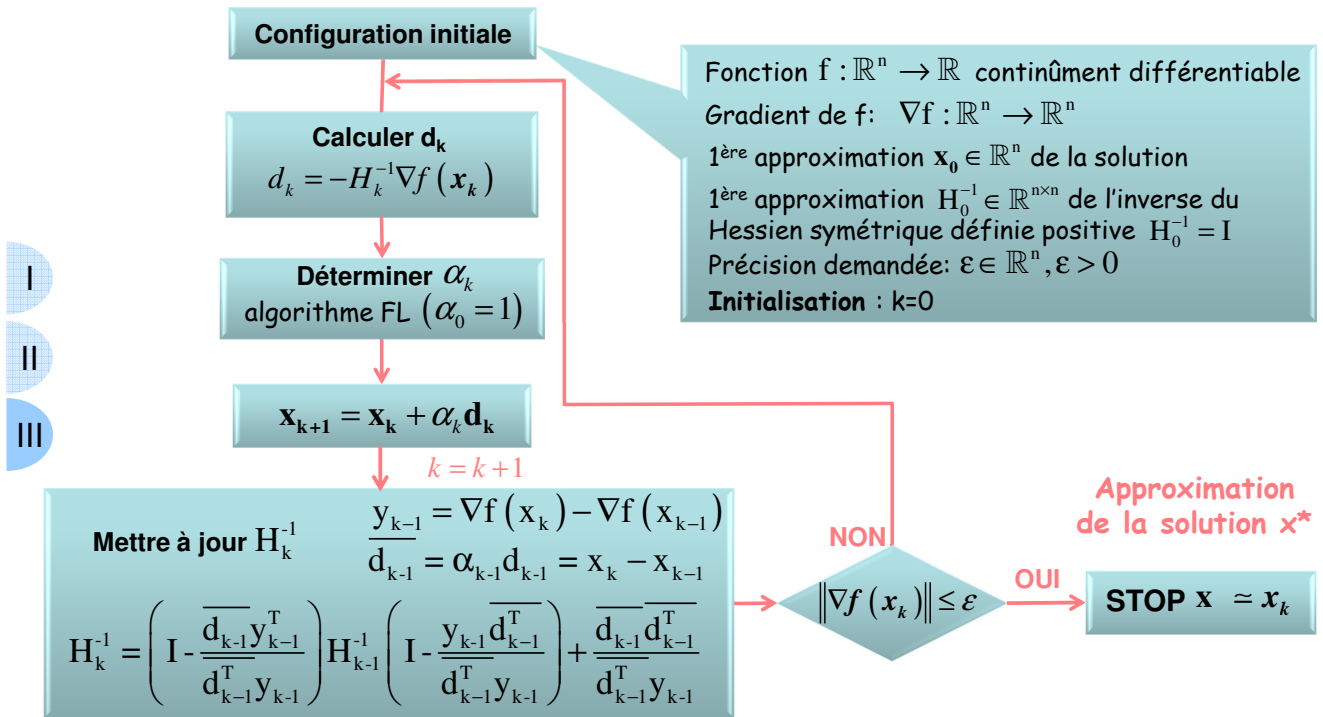
$$d_k = -H_k^{-1} \nabla f(x_k) \quad \text{avec} \quad H_k^{-1} = \left(I - \frac{d_{k-1} y_{k-1}^T}{d_{k-1}^T y_{k-1}} \right) H_{k-1}^{-1} \left(I - \frac{y_{k-1} d_{k-1}^T}{d_{k-1}^T y_{k-1}} \right) + \frac{d_{k-1} d_{k-1}^T}{d_{k-1}^T y_{k-1}}$$

Démonstration en appliquant la formule de Sherman-Morrison-Woodbury à H_k

28

V) Méthodes de Quasi-Newton

B) Méthode BFGS



29

V) Méthodes de Quasi-Newton

C) Autres méthodes ...

Autres formules de mise à jour pour la matrice Hessienne

Autres méthodes de Quasi-Newton

➤ BFGS = mise à jour de rang 2 $\iff (\mathbf{H}_k - \mathbf{H}_{k-1})$ Matrice de rang 2

➔ Mise à jour symétrique de rang 1 (SR1)

$$\mathbf{H}_k = \mathbf{H}_{k-1} \pm \mathbf{v} \mathbf{v}^T \text{ où } \mathbf{v} \in \mathbb{R}^n$$



SR1 ne génère pas forcément une matrice définie positive même si \mathbf{H}_{k-1} l'est!!!

Rang d'une matrice A

$\text{rang}(A)$ est la dim du sous espace $\text{Im}(A) = \{ \mathbf{y} \in \mathbb{R}^m \mid \exists \mathbf{x} \in \mathbb{R}^n \text{ tq } \mathbf{y} = A\mathbf{x} \}$

$A \in \mathbb{R}^{m \times n}$ Nb de valeurs singulières non nulles de A

➤ Mise à jour de Davidon étudiée par Fletcher et Powell (DFP)

➤ Etc...

30